

در واقع می‌توان این‌طور استدلال کرد:

- یک نفر روی **Data Understanding + Classical ML + Transformer** کار کند.
- یک نفر روی **Deep Learning + Evaluation + Reporting + Presentation** کار کند.

از بیرون این تقسیم‌بندی کاملاً منطقی به نظر می‌رسد و حجم کار هم تقریباً متعادل است.

برنامه اجرایی پروژه Jigsaw Toxic Comment Classification

بازه زمانی: 26 خرداد تا 8 تیر

هدف نهایی

تحويل موارد زیر تا 8 تیر:

- GitHub Repository
- Kaggle Submission
- Report PDF
- Presentation
- مقایسه چند مدل مختلف

فاز 1: آشنایی با داده و آماده‌سازی

26 خرداد

نفر دوم	نفر اول
مطالعه Competition Overview	دانلود Dataset و بررسی ساختار فایل‌ها
مطالعه Evaluation Metric	بررسی برچسب‌های Toxic ، Insult و ...
جمع‌آوری چند Notebook مرجع	ساخت Repository و پوشه‌بندی پروژه

خروجی روز

- ساختار پروژه

- آشنایی کامل با دیتاست

27 خرداد

نفر اول	نفر دوم
بررسی تعداد نمونه‌ها	بررسی روش‌های رایج مسابقه
بررسی Missing Value ها	مطالعه مدل‌های BiLSTM
تحلیل توزیع کلاس‌ها	آماده‌سازی محیط PyTorch

تمرکز

درک این که چه کلاس‌هایی نامتوازن هستند و چه چالش‌هایی در داده وجود دارد.

28 خرداد

نفر اول	نفر دوم
رسم نمودارهای EDA	آماده‌سازی Pipeline اولیه داده
Word Frequency Analysis	بررسی نحوه Tokenization
Correlation بین Label ها	آماده‌سازی Notebook مدل

خروجی فاز

- EDA.ipynb
- نمودارهای اولیه

1 Milestone ► (پایان 28 خرداد)

باید آماده باشد:

✓ شناخت کامل دیتاست

✓نمودارهای EDA

✓ساختار Repository

فاز 2 Classical NLP Pipeline :

29 خرداد

نفر اول	نفر دوم
Text Cleaning	آماده سازی Data Loader
حذف URL و علائم اضافی	آماده سازی Embedding Pipeline
Lowercase و Normalization	بررسی Word Embedding ها

تمرکز

ساخت نسخه تمیز داده برای تمام مدل ها

30 خرداد

نفر اول	نفر دوم
TF-IDF	طراحی BiLSTM
N-Gram Features	تعریف ساختار مدل
آماده سازی Feature Matrix	آماده سازی آموزش

خروجی

Feature Matrix آماده مدل سازی

31 خرداد

نفر اول	نفر دوم
Logistic Regression	آموزش BiLSTM
تنظیم Hyperparameter ها	ثبت نتایج اولیه
ذخیره نتایج	تحلیل خطاهای اولیه

1 تیر

نفر اول	نفر دوم
Naive Bayes	تکمیل BiLSTM
SVM	محاسبه معیارها
مقایسه مدل های کلاسیک	جدول نتایج

خروجی فاز

- Logistic Regression
- Naive Bayes
- SVM
- BiLSTM

Milestone 2 ► (پایان 1 تیر)

باید آماده باشد:

✓ حداقل 4 مدل اجرا شده

✓ جدول اولیه نتایج

✓ مقایسه Baseline ها

فاز 3: مدل های پیشرفته و تحلیل

2 تیر

نفر اول	نفر دوم
آماده سازی داده برای DistilBERT	پیاده سازی Evaluation Pipeline
مطالعه HuggingFace	محاسبه ROC-AUC
Transformer مخصوص Tokenization	محاسبه Recall و Precision

3 تیر

نفر اول	نفر دوم
Fine-Tuning DistilBERT	تحلیل نتایج مدل ها
تنظیم Learning Rate	تهیه جداول مقایسه
ذخیره Checkpoint ها	تهیه نمودارها

4 تیر

نفر اول	نفر دوم
Error Analysis	مقایسه نهایی همه مدل ها
بررسی نمونه های اشتباه	آماده سازی Submission
انتخاب بهترین مدل	ثبت نتایج نهایی

► Milestone 3 (پایان 4 تیر)

باید آماده باشد:

✓ DistilBERT

✓ Evaluation کامل

✓ Kaggle Submission

✓ جدول نهایی مقایسه

فاز 4: گزارش

5تیر

نفر اول	نفر دوم
نوشتن Dataset Description	نوشتن Results
Methodology	نوشتن Evaluation
توضیح Pipeline	آماده سازی جداول

6تیر

نفر اول	نفر دوم
Discussion	نمودارها
Conclusion	قالب بندی گزارش
بازبینی نهایی	بازبینی نهایی

► Milestone 4 (پایان 6 تیر)

باید آماده باشد:

✓ گزارش کامل

✓ جداول و نمودارها

فاز 5: ارائه

7 تیر

نفر اول	نفر دوم
آماده سازی متن ارائه	طراحی اسلاید
انتخاب نکات کلیدی	تکمیل اسلایدها

8 تیر

نفر اول	نفر دوم
تمرین ارائه	تمرین ارائه
رفع اشکالات	رفع اشکالات

تحويل نهایی (8 تیر)

باید موجود باشد:

- GitHub Repository مرتب
- Report PDF
- Presentation PPT
- Submission.csv
- Notebook های نهایی

این تقسیم بندی از نظر حجم کار متعادل است؛ هر دو نفر هم بخش فنی مدل سازی دارند و هم در خروجی نهایی پروژه سهم مشخص و قابل دفاعی خواهند داشت.